AstroML. Этап 4: переносимость калибровки

Итог исследования: переносимый выигрыш по заранее выбранному критерию не получен. Это завершённый синтетический CPU-эксперимент с отрицательным основным результатом.

Вопрос: можно ли сделать положительные решения надёжнее при новом семействе отрицательных событий и новом шуме, сохранив coverage не ниже 80%?

Joint-shift, смесь условий	Новый RF confidence (B)	Модель риска (E)
FP / все отрицательные, %, 95% CI	2.53 [2.00; 3.35]	4.94 [3.61; 5.96]
Coverage, %, 95% CI	88.51 [87.42; 89.70]	81.40 [79.71; 82.64]
Принятый recall всех positives, %	41.11	46.31
FP / принятые отрицательные, %	2.82	6.10
FP / все положительные решения, %	5.79	9.65

E повышает recall, но повышает FPR. Разность E-B: +2,42 процентного пункта, 95% CI [1,21; 3,17]. Только 3 из 9 условий проходят все критерии. При удалении пика coverage E составляет 55-59%.

Зарезервированный финальный test не открыт. Все данные здесь синтетические. Обнаружение PSPL-подобного события не определяет массу или тип линзы.

Источник: artifacts/experiment04-main; полный текст: reports/experiment_04.md. Дата исходного опыта: 23.10.2026. Инженерная работа выполнена с помощью Codex.

Протокол и независимость источников

Протокол зафиксирован до основного запуска (commit 5483c93). Все версии одного латентного источника, включая классы, маски и шум, остаются в одном разделе. Старые evaluation этапов 2-3 не используются как новый слепой test.

Раздел	Источников / seed	Всего	Назначение
train	200	600	RF
risk_train	400	1200	Независимое обучение риска кандидата
validation	100	300	Выбор leaf / C по Brier
calibration	1000	3000	Только выбор порогов
evaluation	400	1200	Новая оценка после freeze

Seeds: 2027, 2028, 2029; namespace 4004. Calibration имеет одну negative-view на источник: повторные наблюдения не увеличивают размер независимой выборки.

Cell	Отрицательное семейство	Шум
00_control	Известная смесь	white
10_family	Новый double_bump	white
01_noise	Известная смесь	Новый Matérn GP + σ bias
11_joint	Новый double_bump	Новый Matérn GP + σ bias

Сравнение парное: одинаковые исходные события, cadence и шум внутри mask-пары. 96 исходных измерений; random40 и peak40 сохраняют по 58 точек. SNR 3 / 15 / 50: соответственно 404 / 401 / 395 evaluation-источников.

Модели, данные и ограничения likelihood

PSPL: $u(t)^2 = u0^2 + ((t-t0)/tE)^2$; $A(u) = (u^2+2)/(u\sqrt{(u^2+4)})$; $F(t) = Fs\ A(u) + Fb + noise$. Время в днях, поток в линейных условных единицах.

Сравниваются constant (1 параметр), Gaussian bump (4) и PSPL (5). Взвешенная подгонка: nonnegative linear variable projection, 6 начальных точек, max_nfev=100. $BIC = \chi^2 + \Sigma \log(2\pi\sigma^2) + k \log n$ на одних наблюдениях.

При коррелированном шуме диагональная Gaussian likelihood неверна. Поэтому BIC используется как comparative score; это не истинная GP likelihood и не доказательство физической природы события.

Известные negatives: Gaussian, асимметричная вспышка, периодическая и квазипериодическая переменность, тренд, переход, box-like артефакт, constant. Новое семейство: две близкие Gaussian-компоненты с согласованными амплитудой и outer FWHM. Это toy-модели, не полный каталог реальной переменности.

Известные шумы: white, AR(1) с двумя амплитудами корреляции, σ_report=0,8σ_true. Новый шум: Matérn 3/2 на нерегулярных временах, ell=12 дней, a=0,8, σ_report=0,65σ_true. Маргинальная дисперсия согласована между классами.

49 признаков извлекаются только из наблюдений и подгонок: временные разрывы, наблюдаемый SNR, BIC/χ^2/остатки, bounds и multi-start diagnostics. Truth, истинный максимум/SNR, family/noise/mask labels не входят в inference.

Отсутствие сходимости, плохая идентифицируемость и потеря измеренного сигнала диагностируются раздельно. Solver success не означает точное восстановление Fs/Fb/u0/tE.

Восемь замороженных методов

Метод	Правило
A_BIC	BIC; empirical 5% Gaussian-white reference; без отказа
A_pool_BIC	Тот же score; independent negative-pool NP threshold
B_legacy_RF	Frozen RF и пороги этапа 3
B_RF_confidence	Новый RF на expanded pool; reference threshold + confidence reject
C_empirical_pool	Тот же RF; empirical negative-pool threshold; без отказа
C_NP_pool	Тот же RF; NP order threshold; без отказа
D_conditional_NP	Два наблюдаемых gap/span bins; NP threshold внутри bin
E_risk_gate (primary)	Независимая LR q_FP среди p_RF>0,5; positive-only rejection

RF: 160 деревьев, depth 8, leaf 10/30 выбирался на validation. Risk LR: C=0,1/1. Обучение риска использует отдельные источники. Cal coverage E уже составлял 72,55-75,85%; после этого пороги не ослаблялись.

NP order statistics - известный метод Tong, Feng & Li (2018), не новый алгоритм проекта. При n=1000, α=5%, δ=5% используется 962-й sorted score. Условия контроля риска не переносятся на произвольный OOD.

Рабочие результаты по каждому условию joint-shift

Предварительный критерий: FPR ≤5%, upper95 ≤7,5%, coverage ≥80%; ограничения на recall исключают фиктивное решение always-negative. Никакого подбора по evaluation.

Условие	N-	B FPR,%	B cov,%	E FPR,% [95% CI]	E upper,%	E cov,%	E recall,%
snr3_complete0	404	5.94	89.98	10.15 [7.18; 13.12]	12.97	89.23	12.13
snr3_peak0.4	404	0.00	77.85	3.47 [1.24; 5.58]	5.36	55.07	4.95
snr3_random0.4	404	6.44	87.13	10.40 [6.93; 13.99]	13.24	80.07	10.89
snr15_complete0	401	1.50	98.38	1.50 [0.25; 2.62]	2.93	99.63	85.79
snr15_peak0.4	401	1.00	70.95	6.98 [2.99; 8.98]	9.45	55.11	10.97
snr15_random0.4	401	4.99	95.89	5.49 [3.24; 7.98]	7.74	96.38	79.05
snr50_complete0	395	0.51	100.00	0.51 [0.00; 1.40]	1.59	100.00	100.00
snr50_peak0.4	395	0.00	77.09	4.30 [2.28; 7.85]	6.39	58.61	15.44
snr50_random0.4	395	2.28	99.62	1.52 [0.51; 2.78]	2.98	98.86	99.49

E проходит complete15, complete50, random50. При SNR3/random40 высокий coverage 80,07% сопровождается FPR 10,40%. При peak15 FPR 6,98%, coverage 55,11%, recall 10,97%. У B в peak15 recall равен нулю: низкий FPR также не является достаточным условием успешного обнаружения.

Pooled coverage E 81,40% скрывает отдельные провалы; его CI [79,71; 82,64]% также не даёт уверенного нижнего ограничения 80%. Ни один из восьми методов не выполняет требования FPR/coverage во всех девяти joint conditions.

Гипотезы и сравнение при coverage 80%

Гипотеза	Фактический статус
H4.1	Общий operational transfer gain не поддержан: FPR E выше B, peak coverage ниже 80%.
H4.2	Частичная описательная поддержка pool calibration; общего контроля subgroup FPR нет.
H4.3	Узкая поддержка candidate-risk ranking: joint AUC 0,802 → 0,826; tail reliability не следует.
H4.4	Общий рост относительно обоих одиночных сдвигов не поддержан.

Cell	B risk80,%	E risk80,%	E-B, п.п., 95% CI
00_control	15.43	9.17	-6.27 [-6.93; -5.63]
10_family	18.98	20.59	1.61 [0.96; 2.21]
01_noise	22.27	19.58	-2.69 [-3.16; -2.16]
11_joint	25.10	23.89	-1.22 [-1.59; -0.72]

Это дополнительный unrestricted selector, ранжирующий оба класса без labels; он отличается от рабочего positive-only gate E. CI здесь условны на frozen calibration. Локальный RC gain на joint не отменяет operational violations; на family-only E ухудшает риск.

Общий coverage может вырасти при новом шуме одновременно с ростом FN: система начинает чаще уверенно говорить 'negative'. Поэтому coverage, recall и три знаменателя ложных тревог рассматриваются одновременно.

Редкость событий, механизмы ошибок и границы вывода

Заданная prevalence π	B: FP / positive answers,%	E: FP / positive answers,%
0.5	5.79	9.65
0.01	85.89	91.36
0.001	98.40	99.07
1e-06	99.99837	99.99906

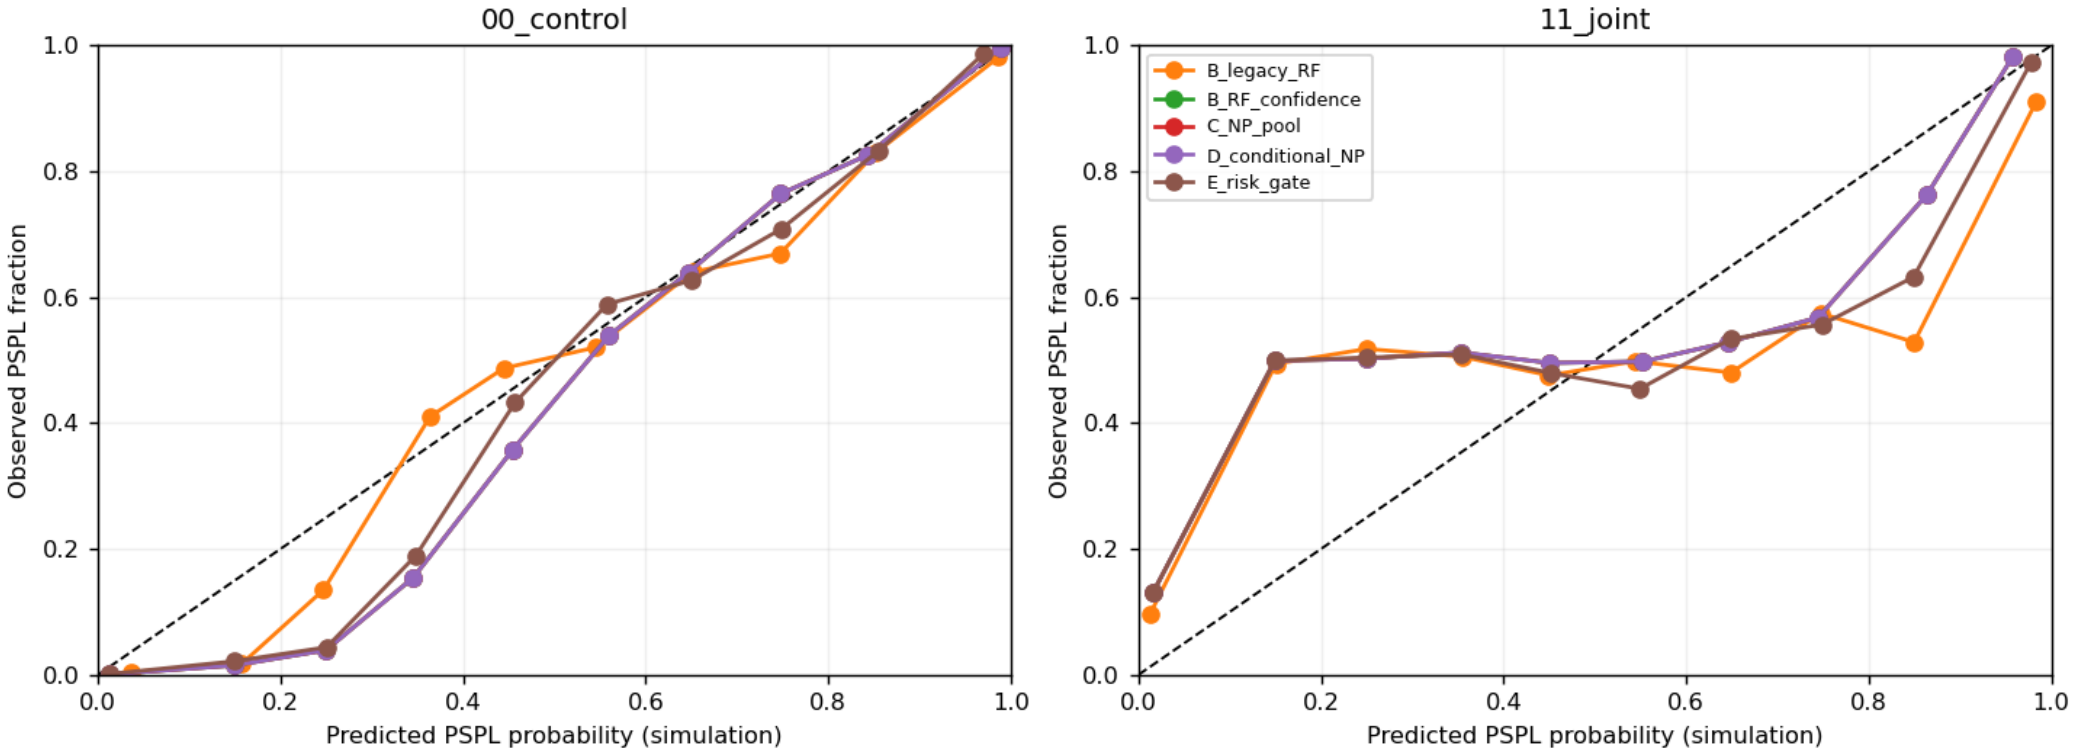
FDRπ = (1-π)FPR / [π Recall + (1-π)FPR]. Это условные сценарии при неизменных class-conditionals, а не измеренная prevalence реального обзора. Balanced simulation не измеряет astronomical precision.

B joint 23 RF-confident FP (p_RF≥0,9) проходят и E. Для 30 выбранных уверенных FP повторена усиленная оптимизация; 29 scores меняются менее чем на 1. Это ограниченный разбор механизмов, не доказательство глобального optimum.

Peak15: median known-pair distance падает с 10,45 до 0,434; median error для двух известных means и истинной covariance - около 41,4%. Это диагностика потери сигнала, не теорема невозможности composite задачи.

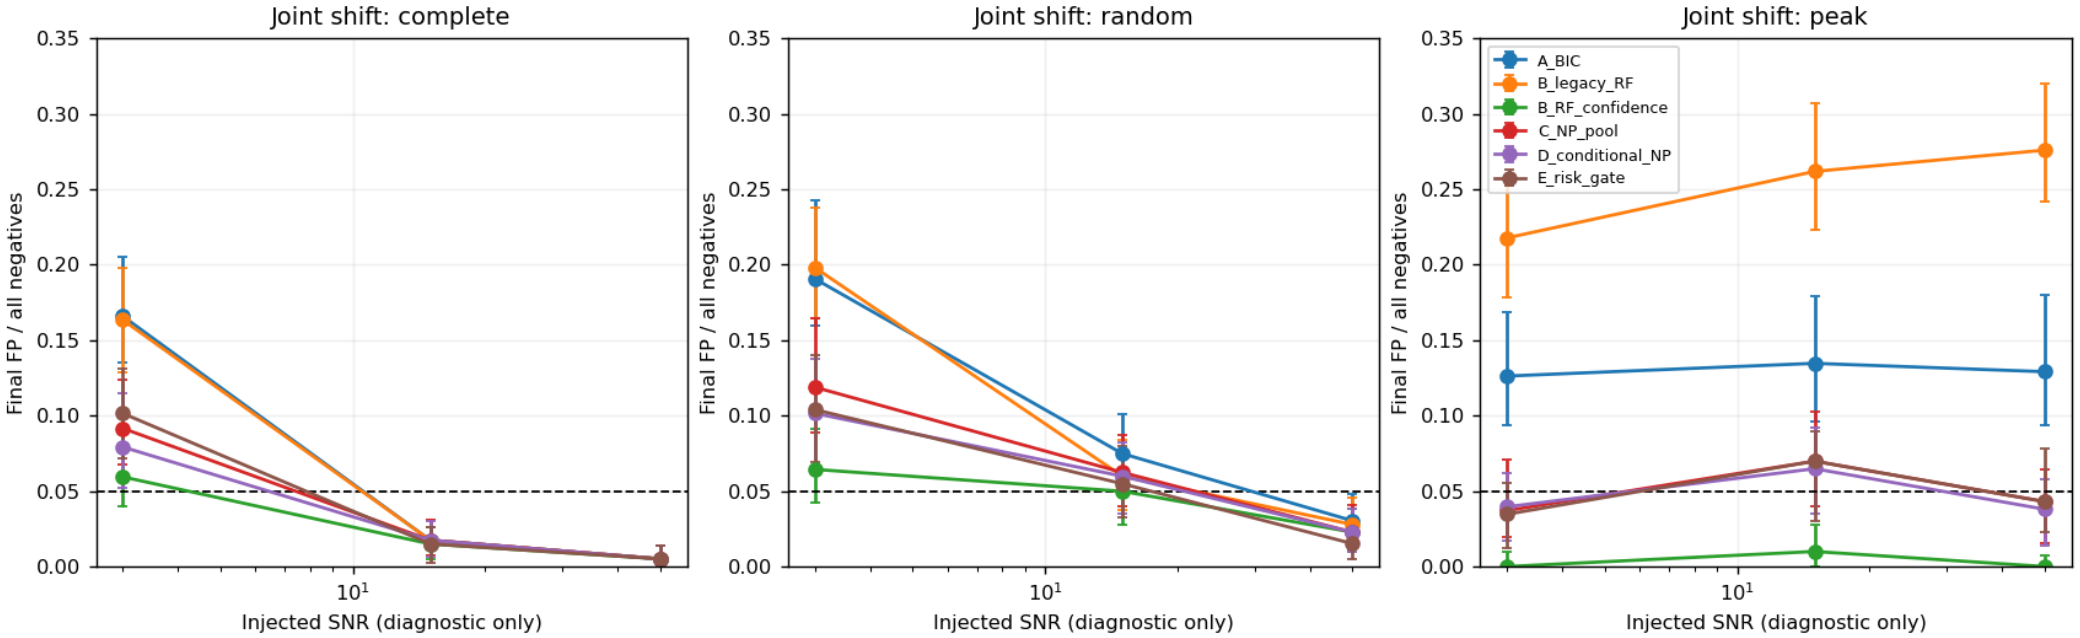
Основные CI: 300 source bootstraps с повторной калибровкой; все paired views вместе. Training/model-selection uncertainty не включена. Family cells малы, pointwise интервалы не дают одновременной гарантии. Нулевые FP не доказывают нулевой риск. Для реального переноса нужны лицензированные survey positives, negatives, quality flags и независимый source split.

Вероятностная калибровка



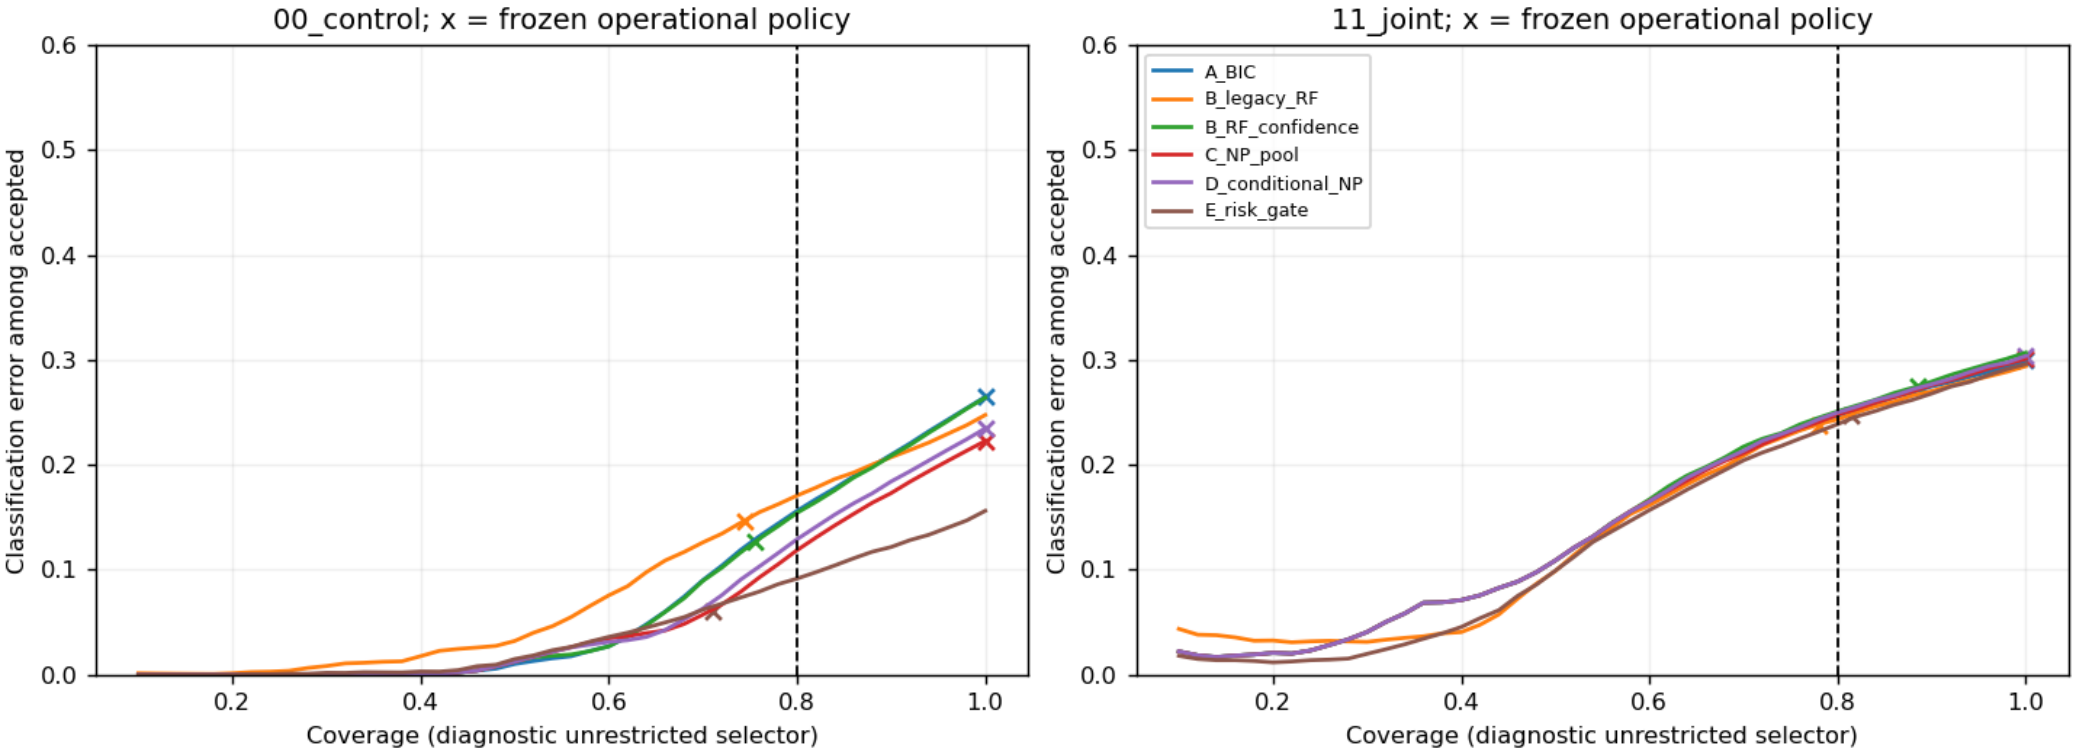
Simulation prevalence 0,5. B/C/D используют один RF, их probability curves совпадают. Смена decision threshold не исправляет probability calibration. BIC не является class probability.

FPR при совместном сдвиге



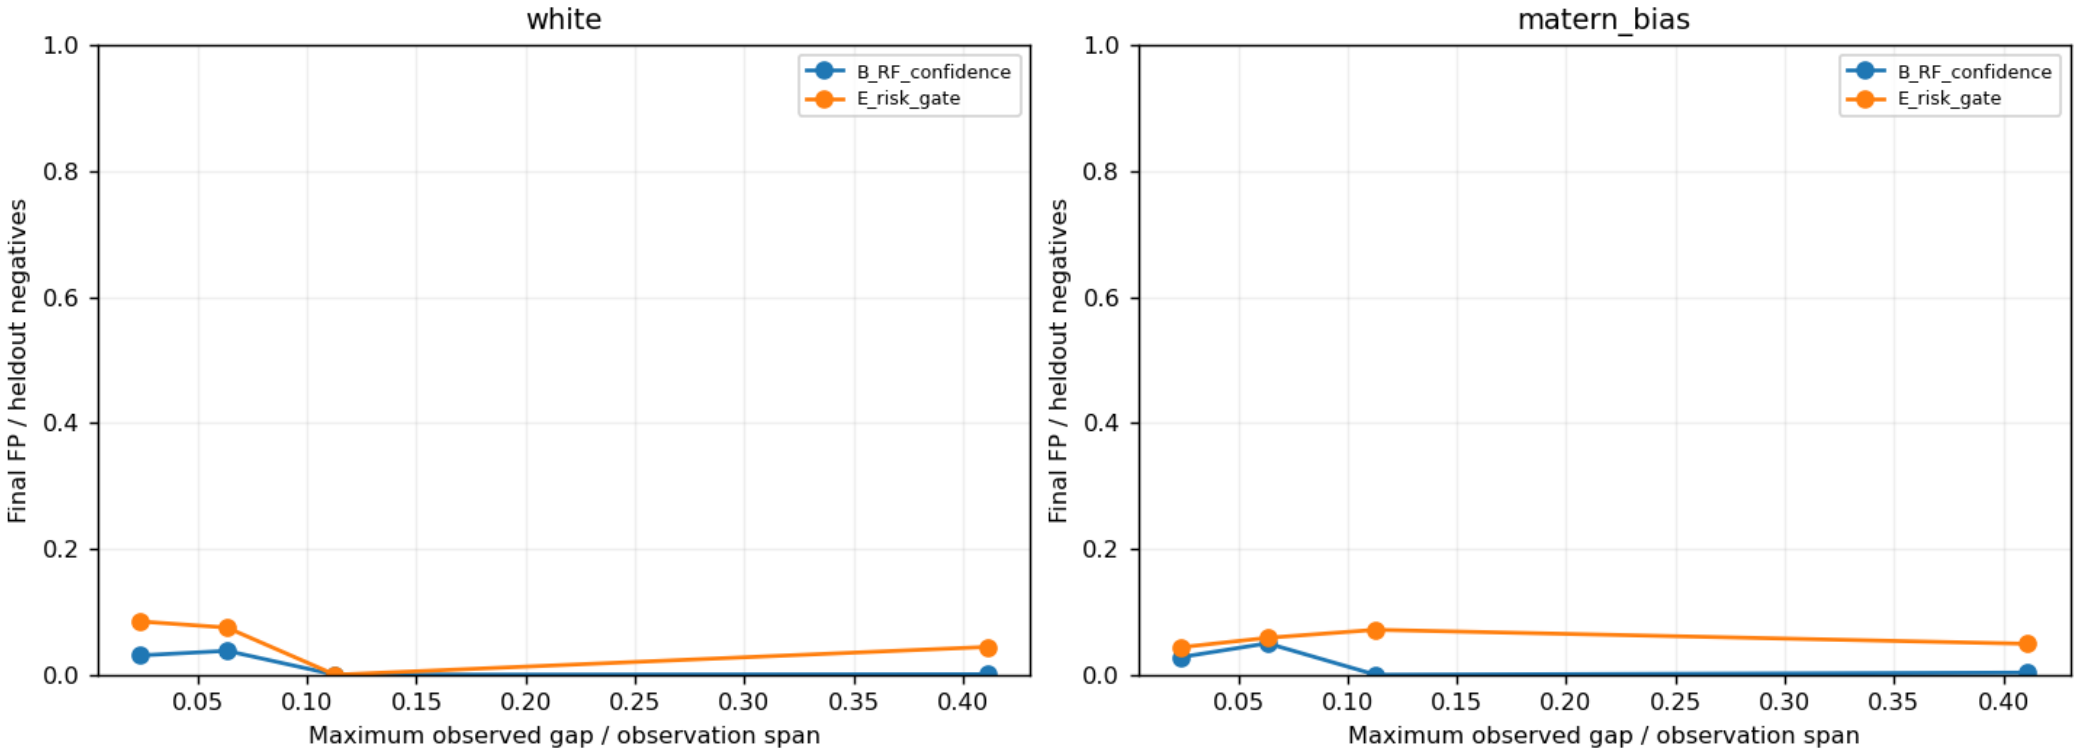
SNR указан только для анализа. Complete/random40/peak40; dashed target 5%. Интервалы: source bootstrap calibration + evaluation. Все точки и CI видны; low FPR сам по себе недостаточен.

Диагностические risk-coverage curves



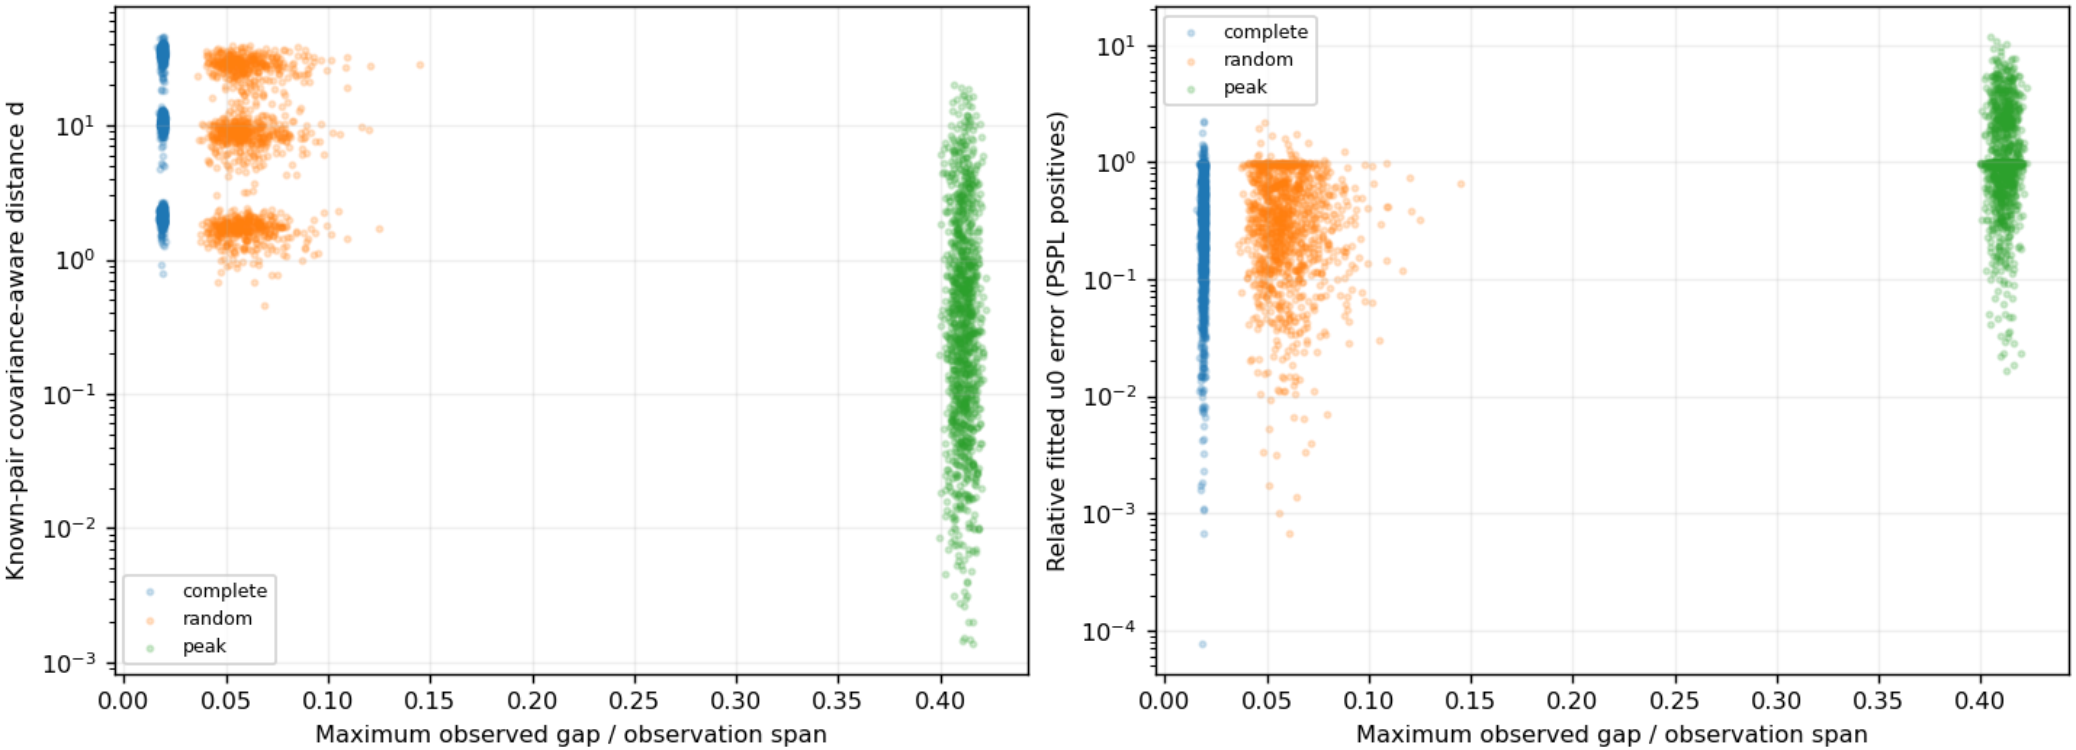
Кресты - рабочая политика с заранее замороженными порогами; линии - иная unrestricted policy. Метки не используются для порядка отбора. Operational E отвергает только positive candidates.

Наблюдаемый разрыв и ложные тревоги



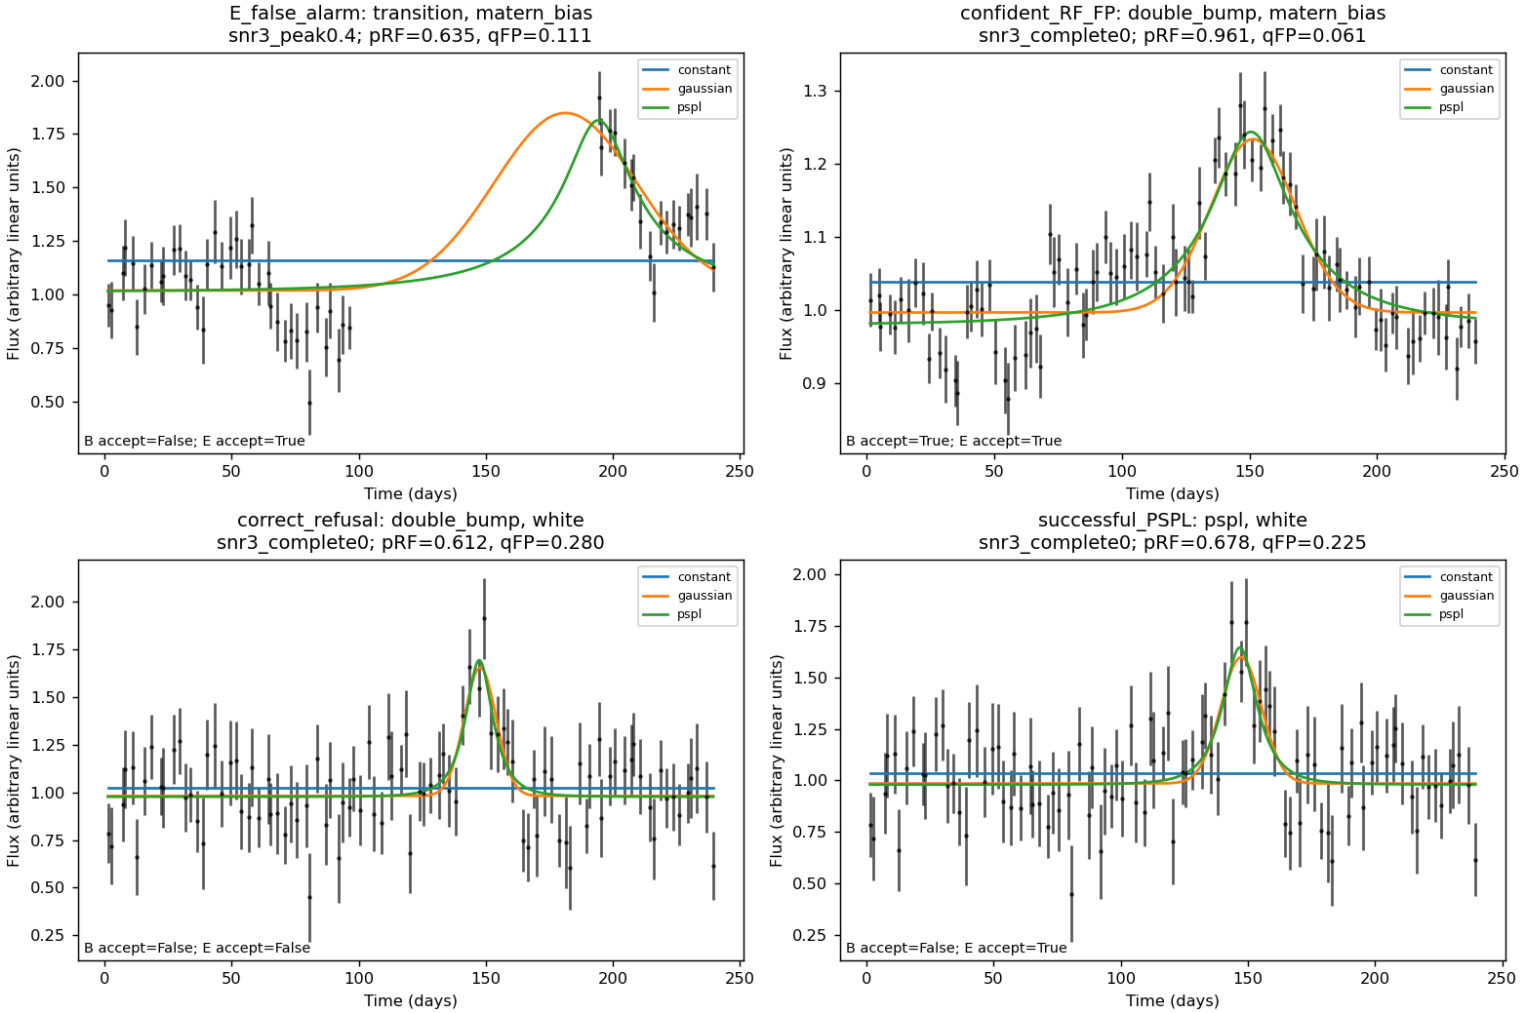
Описание связи gap/span и final FP на double_bump. Это не причинная оценка изолированного влияния gap при всех остальных неизменных условиях.

Информативность и ошибки параметров



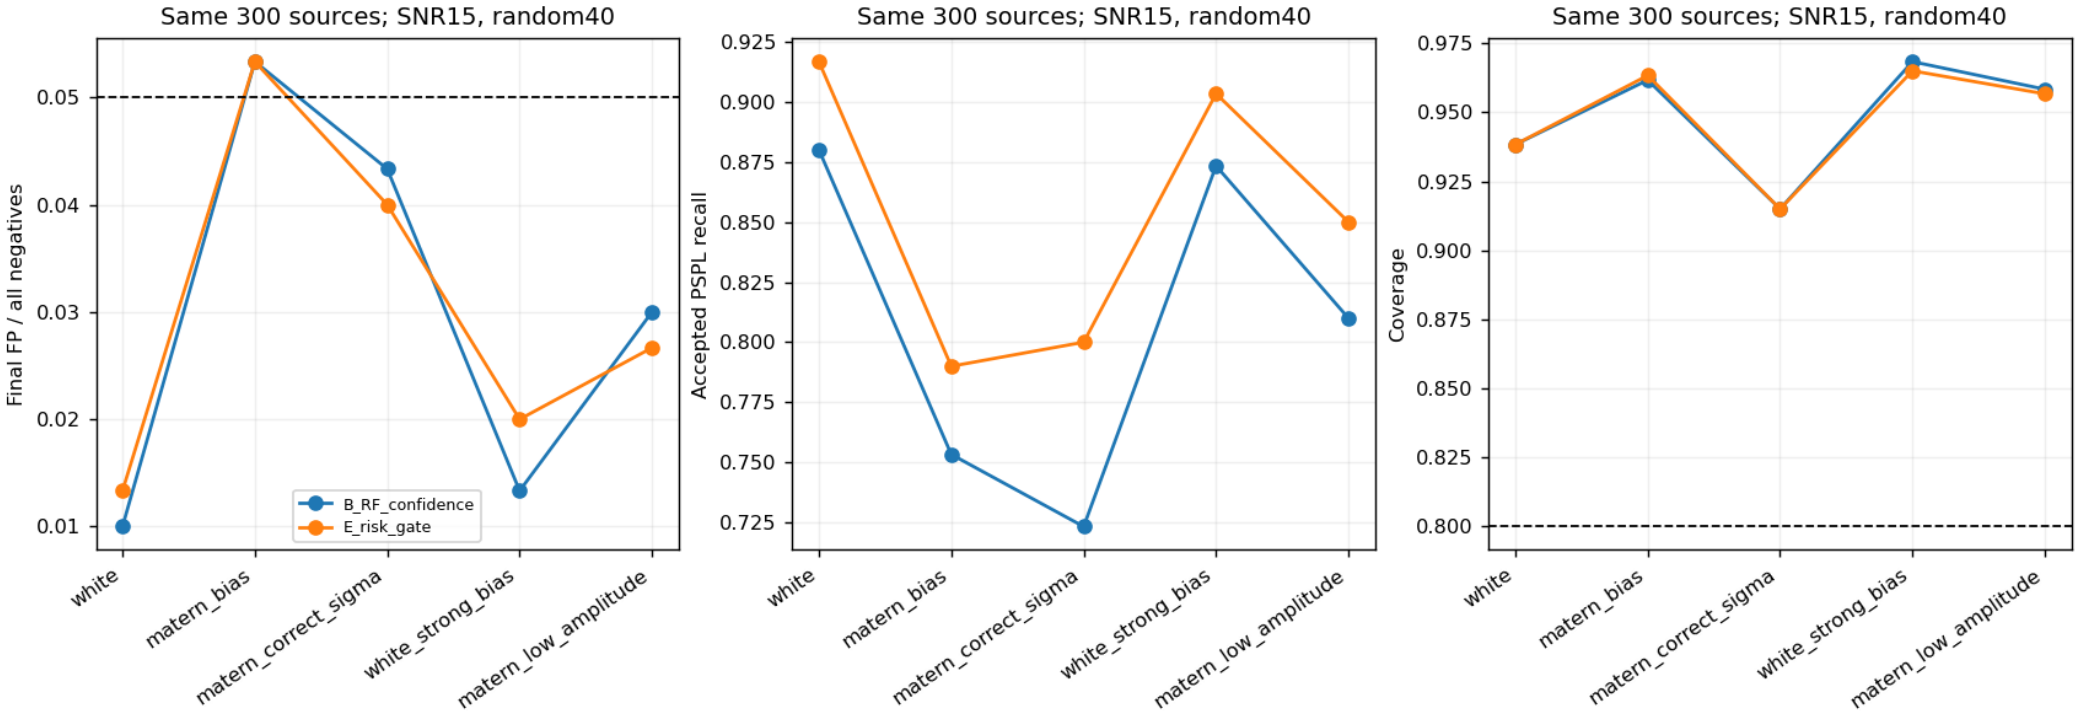
Oracle использует истинную covariance только для анализа. Ошибки u0 и known-pair distance не являются входами detector. Formal solver success не означает идентифицируемость.

Сохранённые примеры решений



Первые подходящие source-order случаи: FP, уверенная ложная тревога, корректный отказ, PSPL. Error bars - сообщённые σ; при bias они меньше истинных. Примеры не оценивают population rate.

Парные проверки шума



Одни 300 источников, SNR15/random40. GP correct_sigma и GP bias имеют одинаковые flux и истинную covariance; меняется inference pipeline. Points descriptive; paired CI в noise_control_contrasts.csv.

Проверки и воспроизведение

Основной CPU run: 753.0 с, четыре процесса, BLAS/OMP=1. GPU и платные ресурсы не использованы. Два smoke дали побитово одинаковые модели/предсказания/пороги; отдельный resume сохранил первый evaluation-open timestamp.

Полный verifier: 6300 уникальных sources, 45900 рядов, 266400 predictions; max $|\Delta\chi^2/\mathrm{BIC}|$=2.9e-11. 54 tests passed, одна optional MulensModel сверка skipped.

Дополнительная независимая сверка итогов: 14612 SHA256, 37072 значений метрик, 320 общих / 960 seed / 1296 family summary rows. Пересчитаны три false-alarm denominator, recall, coverage, selective risk, ROC/AP/Brier, prevalence-сценарии и criteria 3/9. Новое обучение не проводилось.

```
python scripts/check_experiment04_completion.py artifacts/experiment04-main
```

Все сырые t/flux/σ, физические fits/starts/BIC, признаки и решения сохранены. Архив FP содержит 1949 rows из 764 sources. Конфигурации, seeds, manifests, bootstrap draws, CSV/JSON predictions и прежние этапы входят в полный архив.

Полный текст: reports/experiment_04.md; кратко руководителю: supervisor_04.md; протокол: research/experiment_04_protocol.md; 25 вопросов комиссии: defense/experiment_04_notes.md; итоговая матрица: reports/experiment_04_completion.md.

Следующая проверяемая гипотеза - noise-aware/robust likelihood против diagonal. Сначала true-covariance oracle как отдельный диагностический control, затем covariance, оценённая без truth. CNN/PINN пока не обоснована. Ученик должен самостоятельно разобрать формулы и повторить smoke; помощь Codex раскрывается.

Известные алгоритмы не объявляются новыми. Проверенные источники и степень доступа: research/literature_matrix.csv; Tong et al. 2018, DOI10.1126/sciadv.aao1659; Rasmussen & Williams 2006, GPML §4; литература по calibration/selective classification и microlensing в research/literature_review.md. Полный systematic review не завершён.